(1.2) Familia $(C^n | n \geq 0)$ este formată din mulţimi disjuncte două câte două. Ca urmare, Propoziţia 3.5.3.1(2) şi (1.1) conduc la:

$$\pi(C^*) = \pi(\bigcup_{n\geq 0} C^n) = \sum_{n\geq 0} \pi(C^n) = \sum_{n\geq 0} \pi(C)^n.$$

Dacă $\pi(C^*)$ este convergentă dar $\pi(C)$ ar fi mai mare sau egal cu 1, atunci seria $\sum_{n\geq 0} \pi(C)^n$ ar fi divergentă, ceea ce constituie o contradicţie.

Reciproc, dacă $\pi(C) < 1$ atunci şirul sumelor parţiale al seriei $\sum_{n\geq 0} \pi(C)^n$ are limită finită, ceea ce înseamnă că seria este convergentă.

Deci $\pi(C^*) < \infty$ dacă şi numai dacă $\pi(C) < 1$.

(2) Presupunem, prin contradicţie, că C nu este cod. Există atunci un cuvânt $u \in C^*$ ce admite cel puţin două factorizări distincte. Fie

$$u = c_1 \cdots c_m = c'_1 \cdots c'_n$$

două astfel de factorizări, unde $c_1, \ldots, c_m, c'_1, \ldots, c'_n \in C$.

Cuvântul $w = uu$ va avea şi el cel puţin două factorizări distincte, printre care

$$w = c_1 \cdots c_m c'_1 \cdots c'_n = c'_1 \cdots c'_n c_1 \cdots c_m.$$

Atunci

$$\begin{aligned} \pi(C)^{m+n} &= \textstyle\sum_{(c''_1,\ldots,c''_{m+n})\in C\times\cdots\times C} \pi(c''_1)\cdots\pi(c''_{m+n}) \\ &= \textstyle\sum_{(c''_1,\ldots,c''_{m+n})\in C\times\cdots\times C} \pi(c''_1\cdots c''_{m+n}) \\ &\geq \pi(C^{m+n}) + \pi(w) \end{aligned}$$

(ultima inegalitate urmează de la faptul că w are cel puţin două descompuneri distincte de lungime $m+n$ şi de la Propoziţia 3.5.3.1(3)). Combinând această relaţie cu ipoteza şi relaţia $\pi(C^{m+n}) = \pi(C)^{m+n}$, obţinem $\pi(w) = 0$, ceea ce contrazice faptul că π este pozitivă. □

Teorema 3.5.3.1. Fie C un cod peste o mulţime nevidă şi cel mult numărabilă A. Atunci, pentru orice distribuţie de probabilitate π pe A, are loc $\pi(C) \leq 1$.

Demonstraţie. Considerăm întâi cazul în care C este cod şi lungimile cuvintelor lui sunt mărginite de un număr natural arbitrar dar fixat. Presupunem deci că există $k \geq 1$ astfel încât

$$C \subseteq A \cup A^2 \cup \cdots \cup A^k$$

(atragem atenţia asupra faptului că C nu este în mod necesar finit deoarece A poate fi infinită). Atunci, pentru orice număr natural $j \geq 1$,

$$C^j \subseteq A \cup A^2 \cup \cdots \cup A^{jk}.$$

În baza Propoziţiei 3.5.3.1(1) obţinem

$$\pi(C^j) \leq jk,$$

iar de la Propoziţia 3.5.3.2(1.1) urmează

$$\pi(C)^j \leq jk,$$

pentru orice $j \geq 1$.

Acum, dacă am presupune $\pi(C) > 1$, relaţia de mai sus ar conduce la o contradicţie (ea trebuie să fie satisfăcută de orice număr natural $j \geq 1$, ceea ce ar implica faptul că o funcţie exponenţială de bază strict mai mare decât 1 este majorată peste tot de o funcţie liniară). Deci $\pi(C) \leq 1$.

Fie acum cazul în care C este un cod arbitrar peste A. Considerăm mulţimile

$$C_n = \{c \in C | |c| \leq n\},$$

pentru orice $n \geq 1$. Conform primei etape a demonstraţiei,

$$\pi(C_n) \leq 1,$$

pentru orice $n \geq 1$, ceea ce ne arată că şirul sumelor parţiale a seriei $\pi(C)$ este majorat de 1. Deci, $\pi(C) \leq 1$. □

Corolarul 3.5.3.1. Fie C un cod peste o mulţime nevidă şi cel mult numărabilă A. Dacă există o distribuţie pozitivă de probabilitate pe A, π, astfel încât $\pi(C) = 1$, atunci C este cod maximal peste A.

Demonstraţie. Presupunem că există o distribuţie de probabilitate pozitivă pe A, π, astfel încât $\pi(C) = 1$, dar C nu este maximal. Atunci, există un cod C' peste A cu $C \subset C'$. Putem presupune că C' conţine exact un cuvânt în plus faţă de C, fie acesta w. Atunci

$$1 = \pi(C) < \pi(C) + \pi(w) = \pi(C') \leq 1,$$

ceea ce constituie o contradicţie. Deci C este maximal. □

Teorema 3.5.3.2. Fie A o mulţime finită şi nevidă şi $d = (d_n)_{n\geq 1}$ o secvenţă de numere naturale, nu toate 0. Atunci există un cod instantaneu peste A cu distribuţia de lungime d dacă şi numai dacă are loc

$$\sum_{n\geq 1} d_n \frac{1}{|A|^n} \leq 1.$$

Demonstraţie. Dacă există un cod instantaneu peste A cu distribuţia de lungime d, atunci inegalitatea de mai sus este satisfăcută, ea fiind caz particular a Teoremei 3.5.3.1 (cazul unei distribuţii uniforme).

Reciproc, să presupunem că secvenţa d satisface inegalitatea din teoremă. Vom arăta că există o secvenţă de mulţimi $(C_n | n \geq 1)$ astfel încât:

(i) $C_n \subseteq A^n$, pentru orice $n \geq 1$;

(ii) $|C_n| = d_n$, pentru orice $n \geq 1$;

(iii) $\bigcup_{i \leq n} C_n$ este cod instantaneu, pentru orice $n \geq 1$.

Observăm că există C_1 care să satisfacă (i), (ii) şi (iii) deoarece d_1 satisface

$$d_1 \leq |A| - \sum_{n \geq 2} d_n \frac{1}{|A|^{n-1}},$$

de unde urmează $d_1 \leq |A|$ (care ne spune că se pot alege d_1 elemente din A care să formeze un cod instantaneu).

Presupunem că există mulţimile $C_1, \ldots, C_n$ care verifică (i), (ii) şi (iii). Vom arăta că mulţimea A^{n+1} are cel puţin d_{n+1} cuvinte care nu au ca prefixe nici unul din cuvintele mulţimii $C_1 \cup \cdots \cup C_n$. Ca urmare, va exista C_{n+1} care să verifice, împreună cu $C_1, \ldots, C_n$, relaţiile de la (i), (ii) şi (iii).

Numărul de cuvinte din A^{n+1} care nu au ca prefixe nici unul din cuvintele mulţimii $C_1 \cup \cdots \cup C_n$ este dat de:

$$\begin{aligned}
|A|^{n+1} - |C_1||A|^n - \cdots - |C_n||A|^1 &= |A|^{n+1} - d_1|A|^n - \cdots - d_n|A|^1 \\
&= |A|^{n+1}(1 - d_1\tfrac{1}{|A|} - \cdots - d_n\tfrac{1}{|A|^n}) \\
&\geq |A|^{n+1} \textstyle\sum_{i \geq n+1} d_i \tfrac{1}{|A|^i} \\
&= d_{n+1} + |A|^{n+1} \textstyle\sum_{i \geq n+2} d_i \tfrac{1}{|A|^i} \\
&\geq d_{n+1}
\end{aligned}$$

(prima inegalitate utilizează ipoteza). Aceasta încheie demostraţia teoremei. □

Această teoremă a fost demonstrată pentru prima dată de Kraft în 1949 [101] pentru cazul codurilor instantanee finite. Inegalitatea din această teoremă este întâlnită în mod frecvent sub denumirea de *inegalitatea lui Kraft*. În 1956, McMillan [136] a arătat că această inegalitate este satisfăcută de orice cod finit, motiv pentru care ea mai poate fi întâlnită şi sub denumirea de *inegalitatea Kraft-McMillan*. Teorema 3.5.3.1 generalizează inegalitatea Kraft-McMillan la coduri şi distribuţii de probabilitate arbitrare.

3.5.4. Coduri Huffman

În 1952, David Huffman [92] a propus o clasă de coduri optime pentru codificarea datelor, optimalitatea fiind înţeleasă ca număr minim de biţi necesari codificării unui caracter al textului sursă. Aceste coduri sunt cunoscute astăzi drept *coduri Huffman*. Ele au constituit tehnica principală de compresie a datelor până prin jurul anilor 1977, când au fost propuse noi tehnici de compresie ce produc rată de compresie sub *entropie*.

Definiţia 3.5.4.1. Se numeşte *sursă de informaţie* orice cuplu $S = (A, \pi)$, unde A este o mulţime nevidă şi cel mult numărabilă, numită *alfabetul sursei de informaţie*, iar π este o distribuţie de probabilitate pe A.

Pe parcursul acestei secţiuni vom considera numai *surse de informaţie finite*, adică surse de informaţie ce au un alfabet finit şi a căror distribuţie de probabilitate este pozitivă.

Definiţia 3.5.4.2. Se numeşte *codificare* a sursei de informaţie $S = (A, \pi)$ orice codificare a alfabetului sursei S.

Definiţia 3.5.4.3. Fie $S = (A, \pi)$ o sursă de informaţie şi $h : A \to \Sigma^*$ un homomorfism. Se numeşte *lungimea medie* a homomorfismului h relativ la sursa de informaţie S numărul real $L_h(S)$ dat prin

$$L_h(S) = \sum_{a \in A} |h(a)|\pi(a).$$

Dacă h este o codificare a sursei de informaţie S, atunci lungimea medie $L_h(S)$ ne furnizează numărul mediu de simboluri necesare codificării prin h a unui simbol al sursei (fiind o medie ponderată a lungimilor cuvintelor cod asociate simbolurilor sursei de informaţie).

Exemplul 3.5.4.1. Fie S sursa de informaţie dată prin

A	a	b	c	d	e	f
π	0,4	0,2	0,1	0,1	0,1	0,1

şi codificarea h

A	a	b	c	d	e	f
h	0	10	1101	1110	1100	1111

Lungimea medie a acestei codificări este 2,4, ceea ce ne spune că, prin această codificare, sunt necesari în medie 2,4 biţi pentru a codifica un simbol al sursei.

Definiţia 3.5.4.4. Se numeşte *cod Huffman* al unei surse de informaţie orice codificare prefix binară de lungime medie minimă a respectivei surse de informaţie (minimalitatea fiind înţeleasă în clasa codurilor prefix binare ale sursei de informaţie în cauză).

Fără a restrânge generalitatea, codurile Huffman vor fi considerate numai peste alfabetul $\{0, 1\}$.

Problema fundamentală care se pune acum este de a stabili dacă există sau nu coduri Huffman asociate surselor de informaţie şi, dacă există, cum pot fi construite astfel de coduri. Vom răspunde la această întrebare introducând întâi conceptul de redusă a unei surse de informaţie.

Definiţia 3.5.4.5. Fie $S = (A, \pi)$ o sursă de informaţie cu $n \geq 3$ simboluri. Se numeşte *redusă* a sursei de informaţie S orice sursă de informaţie $S' = (A', \pi')$ ce satisface:

1. $A' = (A - \{a, b\}) \cup \{c\}$, unde $a, b \in A$ sunt două simboluri distincte de probabilitate minimă în S (adică, $\pi(d) \geq \pi(a)$ şi $\pi(d) \geq \pi(b)$, pentru orice $d \neq a, b$), iar c este un simbol nou;

2. $\pi'(x) = \pi(x)$, pentru orice $x \in A - \{a, b\}$, şi $\pi'(c) = \pi(a) + \pi(b)$.

Este uşor de văzut că definiţia de mai sus este consistentă în sensul că redusa unei surse de informaţie este sursă de informaţie.

O sursă de informaţie poate avea mai multe reduse, depinzând de simbolul nou introdus (ceea ce nu este relevant) şi de simbolurile reduse (pot exista mai mult de 2 simboluri cu probabilitate minimă).

Vom adopta următoarele notaţii relativ la surse de informaţie:

- orice sursă de informaţie va fi scrisă în forma

$$\begin{array}{c|ccccc} A & a_1 & a_2 & \cdots & a_{n-1} & a_n \\ \hline \pi & p_1 & p_2 & \cdots & p_{n-1} & p_n \end{array}$$

  cu $p_1 \geq p_2 \geq \cdots \geq p_{n-1} \geq p_n$;

- orice redusă a unei surse de informaţie cum e cea de mai sus va fi scrisă în forma

$$\begin{array}{c|ccccc} A' & a_1 & a_2 & \cdots & a_{n-2} & a_{n-1,n} \\ \hline \pi' & p_1 & p_2 & \cdots & p_{n-2} & p_{n-1,n} \end{array}$$

  cu $p_{n-1,n} = p_{n-1} + p_n$ (simbolurile eliminate sunt a_{n-1} şi a_n, iar cel nou introdus este $a_{n-1,n}$).

În raport cu o ordonare fixată a simbolurilor sursei de informaţie S şi cu notaţia adoptată pentru simbolul nou introdus, putem spune că S' este unica redusă a sursei de informaţie S. Din acest punct de vedere ne vom referi adesea la "redusa unei surse de informaţie" construită aşa cum este prezentat mai sus.

Orice sursă de informaţie cu două simboluri admite drept cod Huffman codul ce asociază 0 unui simbol şi 1 celuilalt. Dacă considerăm o sursă de informaţie cu trei simboluri,

$$S = (\{a_1, a_2, a_3\}, \pi),$$

atunci o idee naturală de a construi coduri Huffman pentru ea este următoarea:

- reducem sursa de informaţie S la o sursă de informaţie cu două simboluri $S' = (\{a_1, a_{2,3}\}, \pi')$ (presupunând $\pi(a_1) \geq \pi(a_2) \geq \pi(a_3)$);

- considerăm un cod Huffman h' pentru S';

- codul h dat prin $h(a_1) = h'(a_1)$, $h(a_2) = h'(a_{2,3})0$ şi $h(a_3) = h'(a_{2,3})1$ este cod Huffman pentru S (ceea ce se poate verifica imediat).

Acest rezultat poate fi generalizat la surse de informaţie arbitrare.

Teorema 3.5.4.1. Au loc următoarele proprietăţi:

(1) orice sursă de informaţie admite coduri Huffman;

(2) dacă S' este redusa unei surse de informaţie S cu $n \geq 3$ simboluri şi h' este cod Huffman al sursei S', atunci codificarea h a sursei de informaţie S, dată prin

$$h(x) = \begin{cases} h'(x), & \text{dacă } x \notin \{a_{n-1}, a_n\} \\ h'(x)0, & \text{dacă } x = a_{n-1} \\ h'(x)1, & \text{dacă } x = a_n, \end{cases}$$

este cod Huffman al sursei S.

Demonstraţie. (1) Fie S o sursă de informaţie cu n simboluri şi h un cod ce asociază fiecărui simbol al ei o secvenţă binară de lungime n (un astfel de cod există întotdeauna, fiind un subcod al codului bloc de lungime n). Atunci $L_h(S) = n$. Există un număr finit de coduri prefix binare ce au lungimea medie cel mult n. Ca urmare, orice cod dintre acestea, ce minimizează lungimea medie, este cod Huffman pentru S.

(2) Vom face demonstraţia în trei etape.

Etapa 1: Arătăm că S admite coduri Huffman h ce satisfac

$$|h(a_1)| \leq \cdots \leq |h(a_n)|.$$

Conform cu (1), S admite coduri Huffman, şi fie h' un astfel de cod. Fie $i < n$. Dacă $p_i > p_{i+1}$, atunci $|h'(a_i)| \leq |h'(a_{i+1})|$ (altfel, am interschimba codul lui a_i cu cel al lui a_{i+1} şi am obţine un cod prefix binar h'' ce ar avea lungimea medie mai mică decât a lui h', ceea ce ar constitui o contradicţie). Dacă $p_i = p_{i+1}$ şi $|h'(a_i)| > |h'(a_{i+1})|$, atunci interschimbăm codul lui a_i cu cel al lui a_{i+1} şi obţinem un nou cod h'' ce are exact aceeaşi lungime medie ca şi h'.

Realizând această transformare pentru orice $i < n$, obţinem un cod Huffman h pentru S ce satisface proprietatea de mai sus.

Etapa 2: Arătăm că S admite un cod Huffman h ce satisface $|h(a_{n-1})| = w0$ şi $|h(a_n)| = w1$ (sau invers), unde w este o secvenţă binară.

Conform etapei 1, S admite un cod Huffman h' ce satisface

$$|h'(a_1)| \leq \cdots \leq |h'(a_n)|.$$

Fie $|h'(a_n)| = wb$, unde $b \in \{0, 1\}$. Considerăm funcţia h'' dată prin:

- $h''(a_i) = h'(a_i)$, pentru orice $1 \leq i \leq n-1$;
- $h''(a_n) = w$.

Atunci $L_{h''}(S) < L_{h'}(S)$, ceea ce arată că h'' nu este cod prefix (altfel el ar avea lungimea medie mai mică decât cea a unui cod Huffman). Cum h' este cod prefix, deducem că singura posibilitate pentru care h'' nu este cod prefix constă în aceea că există $i < n$ astfel încât w este prefix în $h'(a_i)$. Atunci $h'(a_i) = wb'$, unde $b' \in \{0,1\}$ şi $b' \neq b$. Şirul de inegalităţi $|h'(a_i)| \leq \cdots \leq |h'(a_n)|$ conduce la

$$|h'(a_i)| = \cdots = |h'(a_n)|.$$

Aceasta ne arată că putem interschimba cuvintele cod $h'(a_i)$ şi $h'(a_{n-1})$, obţinând un nou cod prefix h ce are aceeaşi lungime medie ca şi h'. Deci h este cod Huffman ce satisface cerinţele acestei etape.

Etapa 3: Fie h' un cod Huffman al sursei S' şi h codul obţinut din h' ca în enunţul teoremei. Este clar că h este cod prefix. Are loc:

$$L_h(S) = L_{h'}(S') + p_{n-1} + p_n.$$

Fie $\bar{h}$ un cod Huffman binar pentru S ce satisface cerinţele etapei 2. Construim codul $\tilde{h}$ pentru S' prin:

- $\tilde{h}(a_i) = \bar{h}(a_i)$, pentru orice $1 \leq i \leq n-2$;
- $\tilde{h}(a_{n-1,n}) = w$.

Este uşor de văzut că $\tilde{h}$ este cod prefix pentru S' şi are loc:

$$L_{\bar{h}}(S) = L_{\tilde{h}}(S') + p_{n-1} + p_n.$$

Atunci:

$$\begin{aligned} L_h(S) &= L_{h'}(S') + p_{n-1} + p_n \\ &= L_{\bar{h}}(S) - (L_{\tilde{h}}(S') - L_{h'}(S')) \\ &\leq L_{\bar{h}}(S) \end{aligned}$$

(ultima inegalitate urmează de la faptul că $L_{\tilde{h}}(S') \geq L_{h'}(S')$). Cum $\bar{h}$ este cod Huffman pentru S, deducem că are loc $L_h(S) = L_{\bar{h}}(S)$, ceea ce arată că h este cod Huffman pentru S. □

Teorema 3.5.4.1 ne arată cum putem construi coduri Huffman asociate surselor de informaţie cu cel puţin trei simboluri. Dată o sursă de informaţie S cu $n \geq 3$ simboluri, procedăm astfel:

- ordonăm simbolurile descrescător după probabilitate, după care reducem sursa de informaţie S obţinând o sursă de informaţie S' cu $n-1$ simboluri. Dacă $n-1 = 2$, atunci putem construi un cod Huffman pentru S', de la care vom putea construi un cod Huffman pentru S;
- dacă S' are cel puţin trei simboluri, atunci repetăm pasul anterior cu S' în locul sursei de informaţie S.

Vom considera un exemplu care să ilustreze aceste operaţii.

Exemplul 3.5.4.2. Fie S sursa de informaţie din tabelul de mai jos:

A	a	b	c	d	e	f
π	$0,4$	$0,2$	$0,1$	$0,1$	$0,1$	$0,1$

"Arborele" din Figura 3.13, citit de la stânga la dreapta, descrie procesul de reducere a sursei de informaţie S până la o sursă de informaţie cu două simboluri.

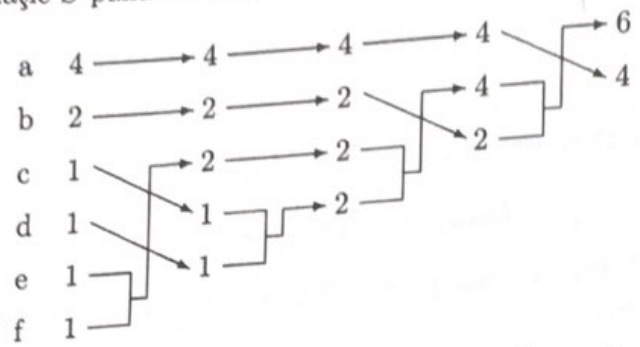

Figura 3.13: Reducerea unei surse de informaţie

Acum, pornind de la dreapta spre stânga, putem asocia coduri Huffman surselor de informaţie obţinute în procesul de reducere. Vom desemna aceste coduri inscripţionând arcele arborelui de mai sus, ca în Figura 3.14.

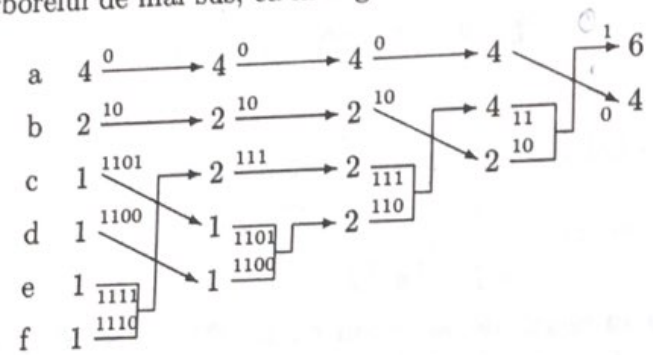

Figura 3.14: Construcţia unui cod Huffman

Lungimea medie (minimă) a acestui cod este

$$4 \cdot 0,1 + 4 \cdot 0,1 + 4 \cdot 0,1 + 4 \cdot 0,1 + 2 \cdot 0,2 + 1 \cdot 0,4 = 2,4$$

Este util de remarcat că reordonarea simbolurilor nu este în general unică, ceea ce poate conduce la coduri Huffman diferite pentru aceeaşi sursă de informaţie. Ceea ce este important este că toate aceste coduri au aceeaşi lungime medie, care este cea minimă. De exemplu, reducerea sursei de informaţie S se poate face şi ca în Figura 3.15. Codul Huffman obţinut prin această nouă reducere nu are cuvinte cod de lungime 4, dar are cuvinte de lungime 3, spre deosebire de cazul anterior. Însă lungimea lui medie este aceeaşi, adică $2,4$.

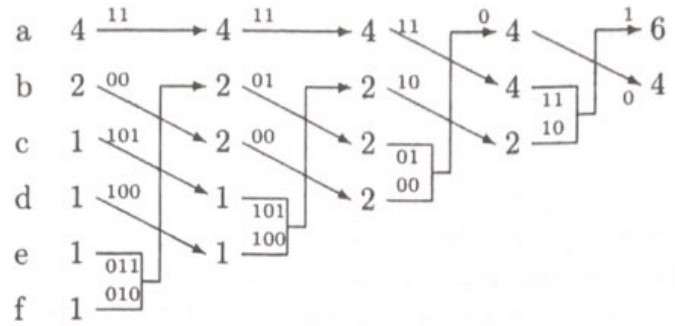

Figura 3.15: O altă reducere a aceleiaşi surse de informaţie

Deoarece codurile Huffman produc lungimi medii minime (conform definiţiei), este natural să ne punem problema compresiei unui text prin utilizarea unui astfel de cod. Tehnica naturală de compresie ce se poate imagina este următoarea. Fie `text` un text. Într-o primă etapă se parcurge textul şi se evidenţiază toate caracterele (simbolurile) ce apar în el, cu numărul lor de apariţii (dar cel puţin una). Fie $a_1, \ldots, a_n$ aceste simboluri şi $\#(a_i, \texttt{text})$ numărul de apariţii ale caracterului a_i în textul `text`. Am obţinut astfel o sursă de informaţie $S = (A, \pi)$, unde $A = \{a_1, \ldots, a_n\}$ şi $\pi(a_i) = \#(a_i, \texttt{text})/|\texttt{text}|$, pentru orice $1 \leq i \leq n$. În cea de a doua etapă vom asocia sursei de informaţie S un cod Huffman h. Atunci compresia textului `text` este dată prin textul $h(\texttt{text})$. Inevitabil, pentru orice alt cod prefix h' pentru S are loc $|h(\texttt{text})| \leq |h'(\texttt{text})|$.

Ca urmare, compresia prin coduri Huffman se realizează în două etape:

- parcurgerea textului pentru determinarea frecvenţei de apariţie a caracterelor în text;
- construcţia codului Huffman şi codificarea textului.

Deci procesul de compresie necesită două parcurgeri ale textului sursă. Pentru accelerarea procesului de compresie se poate recurge la o variantă a codificării Huffman în care textul sursă să fie scanat doar o singură dată. Ideea este foarte simplă şi poate fi descrisă astfel:

- să presupunem că prefixul u al textului sursă $\texttt{text} = uav$ a fost parcurs şi i s-a asociat codul Huffman h_u;
- simbolul următor ce trebuie scanat, a, va fi codificat prin codul lui în h_u (deci prin $h_u(a)$), după care se va construi un cod Huffman h_{ua} pentru ua pornind de la h_u.

Pentru ca această metodă să funcţioneze corect este necesar ca iniţial să se pornească de la un cod Huffman asociat secvenţei $a_1 a_2 \cdots a_n$, presupunând că textul `text` este peste un alfabet $A = \{a_1, \ldots, a_n\}$. Metoda descrisă mai sus poartă denumirea de *metoda Huffman adaptivă*. Se observă că, prin această metodă, un caracter a poate fi codificat diferit în funcţie de poziţia lui în text. Ca urmare, metoda Huffman adaptivă

nu produce un cod asociat alfabetului A. Se poate arăta că, de fapt, acestă tehnică este specifică clasei codurilor variabile în timp [199, 200].

Să ne întoarcem la metoda Huffman adaptivă şi să vedem cum poate fi transformat în mod eficient codul Huffman h_u într-un cod Huffman h_{ua}. Tehnica este foarte simplă şi se bazează pe faptul că frecvenţa de apariţie a simbolului a în h_u creşte cu o unitate. Aceasta face ca simbolul a să avanseze, posibil, spre început. Pentru o descriere elegantă a acestui aspect vom face apel la reprezentarea arborescentă a codurilor prefix. Frunzele acestui arbore sunt caracterele ce se codifică, iar drumul de la rădăcină la frunză furnizează codul asociat caracterului în cauză. Nodurile arborelui, etichetate cu frecvenţe de apariţie a simbolurilor (inclusiv a noilor simboluri obţinute prin reducere) sunt ordonate crescător, de la stânga la dreapta şi de la frunze spre rădăcină (pe nivele). De exemplu, codul din Figura 3.15 este reprezentat arborescent ca în Figura 3.16 (pentru fiecare nod ce nu este frunză, ramura ce conduce la descendentul stâng al acestuia este considerată ca fiind etichetată cu 0, iar cealaltă cu 1; astfel, codul lui f este 010 etc.).

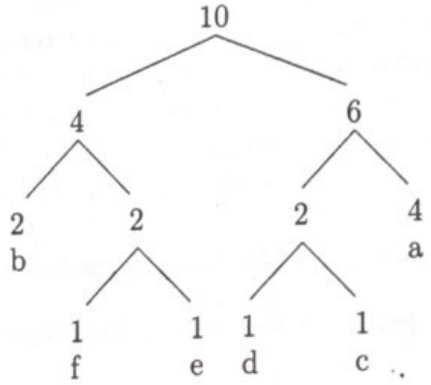

Figura 3.16: Reprezentare arborescentă a codurilor Huffman

Să presupunem că u este un text ce produce codul din Figura 3.15, acel cod fiind de fapt h_u (în notaţia de mai sus). Să presupunem că următorul simbol scanat este e. În vechea sursă de informaţie, frecvenţa simbolului e creşte cu o unitate. Vom conveni ca noua sursă de informaţie să fie obţinută din prima prin interschimbarea poziţiei lui c cu a lui e. Procedând în acest mod vom obţine codul h_{ue} din Figura 3.17 ce are asociat arborele din Figura 3.18.

Interschimbarea ce am făcut-o pentru sursa iniţială de informaţie din Figura 3.17 se reflectă şi în cadrul reducerilor ce se realizează mai departe, în sensul că aceste reduceri se realizează exact după aceeaşi politică. Generalizând, stabilim că metoda de obţinere a codului h_{ua} din codul h_u este următoarea (în termeni de arbore asociat codului):

- compară a cu succesorii din arborele asociat lui h_u (de la stânga la dreapta şi de jos în sus). Dacă succesorul imediat are frecvenţa $k+1$ (presupunând că frecevenţa lui a este k), atunci nodurile sunt în ordine. Altfel, a va trebui

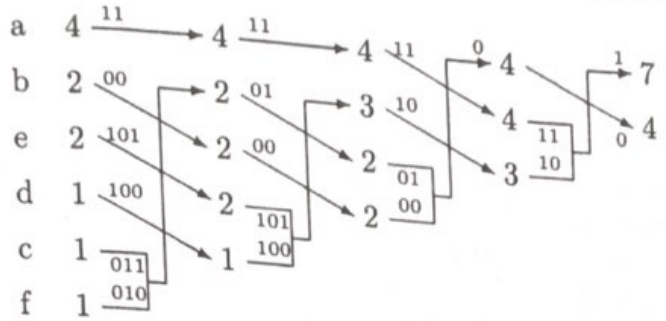

Figura 3.17: Construcţia codului h_{ue}

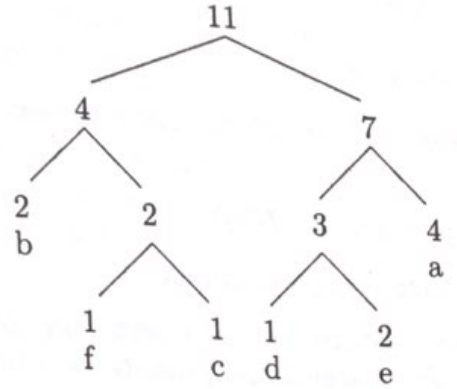

Figura 3.18: Reprezentare arborescentă a codului h_{ue}

înlocuit cu ultimul succesor ce are frecvenţa k sau mai mică (exceptând cazul în care succesorul este părintele lui a);

- incrementează frecvenţa lui a de la k la $k+1$;
- dacă a este rădăcina arborelui, atunci transformarea este încheiată; altfel, se repetă paşii anteriori cu părintele lui a în locul lui a.

În practică se dovedeşte că metoda Huffman adaptivă este de preferat metodei Huffman "în doi paşi". Cum această secţiune nu are scopul de a acoperi în întregime tehnica de compresie Huffman adaptivă, cititorul interesat de detalii asupra acesteia este îndrumat către [173, 175].

3.5.5. Entropie. Limita compresiei

Conceptul de entropie, ca măsură a informaţiei şi a gradului de incertitudine, a fost introdus în 1948 de către Claude Shannon [181]. Noţiunea este preluată din termodinamică, unde entropia măsoară gradul de dezordine al unui sistem fizic. Termenul "entropie" a fost utilizat pentru prima dată de Clausius in 1864.

Pentru o introducere facilă a conceptului de entropie vom urma [79, 166]. Fie $S = (\{a_i | 1 \leq i \leq n\}, (p_i | 1 \leq i \leq n))$ o sursa de informaţie. Dacă $p_i = 1/n$ pentru orice i, atunci *gradul de incertitudine* al apariţiei simbolurilor sursei este maxim (ne putem aştepta la apariţia oricărui simbol al sursei, în egală măsură). Dacă $p_1 = 1$ (restul probabilităţilor fiind 0), atunci nu este nici o surpriză faptul că simbolul emis de sursă este numai a_1. Ca urmare, putem spune că gradul de incertitudine este 0. Pe măsură ce p_1 scade şi cresc celelalte probabilităţi, gradul de incertitudine creşte, ajungând să fie maxim atunci când toate simbolurile au aceeaşi probabilitate.

Cum am defini gradul de incertitudine al apariţiei unui simbol a cărui probabilitate de apariţie este p? Facem întâi observaţia ca acest grad de incertitudine nu trebuie să depindă de simbol, ci numai de probabilitatea de apariţie a acestuia. Dacă notăm prin $I(p)$ gradul de incertitudine al apariţiei unui astfel de simbol, atunci este natural să presupunem că $I(p)$ trebuie să satisfacă următoarele proprietăţi:

1. (măsură reală pozitivă) $I(p) \geq 0$ şi $I(p) = 0$ dacă şi numai dacă $p = 0$ sau $p = 1$;
2. (aditivitate) $I(p_1 p_2) = I(p_1) + I(p_2)$;
3. (continuitate) $I(p)$ este funcţie continuă.

Proprietatea de aditivitate conduce la $I(p^m) = mI(p)$, pentru orice $0 \leq p \leq 1$ şi $m \in \mathbf{N}$. Considerând $p = q^{1/m}$, aceeaşi proprietate de aditivitate conduce la $I(q) = mI(q^{1/m})$, de la care urmează

$$I(q^{m/k}) = (m/k)I(q),$$

pentru orice $m, k \in \mathbf{N}$ cu $k \neq 0$. Ca urmare, funcţia I se comportă ca şi funcţia logaritm pentru cazul puterilor raţionale. Cerinţa de continuitate ne permite să extindem această proprietate la puteri reale şi, totodată, să considerăm forma funcţiei $I(p)$ ca fiind

$$I(p) = \begin{cases} 0, & \text{dacă } p = 0 \\ k \log p, & \text{altfel,} \end{cases}$$

unde logaritmul este într-o bază nespecificată. Pentru a avea satisfăcută şi prima cerinţă asupra acestei funcţii, este natural a considera $k = -1$. Ca urmare, am fi tentaţi să presupunem forma funcţiei I ca fiind

$$I(p) = \begin{cases} 0, & \text{dacă } p = 0 \\ -\log p = log(1/p), & \text{altfel.} \end{cases}$$

Revenind la baza logaritmului, putem spune că aceasta nu este importantă, ca urmare a proprietăţii de schimbare a bazei şi a proprietăţii de aditivitate pe care o satisface I. Astfel, ea va fi considerată în tot ceea ce urmează ca fiind 2.

Întrebarea care se pune acum este dacă mai există şi altă funcţie, să zicem $g(p)$, care să satisfacă proprietăţile 1–3 de mai sus. Vom arăta ca o astfel de funcţie este în mod necesar de forma

$$g(p) = \begin{cases} 0, & \text{dacă } p = 0 \\ C \log(1/p), & \text{altfel,} \end{cases}$$

ceea ce ne spune că funcţia I este unică până la o constantă de proporţionalitate.

În adevăr, dacă $g(p)$ este o funcţie ce satisface proprietăţile 1–3, atunci urmează că are loc $g(p^m) = mg(p)$, pentru orice $m \in \mathbf{N}$, de la care obţinem

$$g(p^m) - C\log(1/p^m) = m(g(p) - C\log(1/p)),$$

pentru orice constantă C şi $p > 0$. Alegând $C = g(p_0)/\log(1/p_0)$ cu p_0 diferit de 0 sau 1, obţinem $g(p_0^m) - C\log(1/p_0^m) = 0$, adică $g(p_0^m) = C\log(1/p_0^m)$, pentru orice $m \in \mathbf{N}$. Cum orice număr real $p \in (0,1)$ poate fi scris în forma $p = p_0^m$ cu o alegere potrivită pentru m, deducem că are loc $g(p) = C\log(1/p)$ pentru orice p de acest tip. În plus, $g(1) = 0 = g(0)$. Aceasta ne arată că funcţia g este de forma menţionată mai sus şi, deci, g şi I diferă între ele doar printr-o constantă.

Am determinat până acum forma pe care ar trebui să o aibă funcţia ce furnizează gradul de incertitudine al apariţiei unui simbol al unei surse. Dacă sursa S are n simboluri, $S = (\{a_i | 1 \le i \le n\}, (p_i | 1 \le i \le n))$, *gradul mediu de incertitudine*, notat $H(p_1, \ldots, p_n)$, este suma ponderată a gradelor de incertitudine asociate simbolurilor sursei. Pentru a exprima în mod elegant această sumă ponderată, convenim ca $0 \cdot log(1/0)$ să fie 0. Atunci putem scrie,

$$H(p_1, \ldots, p_n) = \sum_{i=1}^{n} p_i \log(1/p_i).$$

Definiţia 3.5.5.1. Fie S o sursă de informaţie cu n simboluri şi distribuţia de probabilitate $p_1, \ldots, p_n$. *Entropia* sursei de informaţie S, notată $H(S)$, este definită ca fiind $H(S) = H(p_1, \ldots, p_n)$.

Ne vom ocupa acum de studiul câtorva proprietăţi de bază a entropiei. Reamintim întâi următoarea inegalitate a cărei demonstraţie poate fi uşor stabilită de către cititor.

Lema 3.5.5.1. Pentru orice $b > 1$ şi $x > 0$, are loc $log_b x \le x - 1$. Inegalitatea este satisfăcută prin egalitate dacă şi numai dacă $x = 1$.

Cu ajutorul acestei leme putem stabili următoarea inegalitate cunoscută sub numele de *inegalitatea lui Gibbs*.

Lema 3.5.5.2. (Inegalitatea lui Gibbs)
Fie $b > 1$ şi $p_1, q_1, \ldots, p_n, q_n$ numere reale astfel încât $0 \le p_i, q_i \le 1$, pentru orice i, $\sum_{i=1}^{n} p_i = 1$ şi $\sum_{i=1}^{n} q_i \le 1$. Atunci

$$\sum_{i=1}^{n} p_i log_b(1/p_i) \le \sum_{i=1}^{n} p_i log_b(1/q_i),$$

cu convenţiile $0 \cdot log(1/0) = 0$ şi $p \cdot log(1/0) = 0$, pentru orice $p > 0$. În plus, inegalitatea este satisfăcută prin egalitate dacă şi numai dacă $p_i = q_i$, pentru orice $1 \le i \le n$.

Demonstraţie. Conform Lemei 3.5.5.1, putem scrie

$$log_b(q_i/p_i) \leq (q_i/p_i) - 1,$$

pentru orice $p_i \neq 0$ şi $q_i \neq 0$. În plus, inegalitatea este satisfăcută prin egalitate dacă şi numai dacă $q_i/p_i = 1$, ceea ce este echivalent cu $p_i = q_i$.

Inegalitatea de mai sus împreună cu convenţiile adoptate conduc la

$$p_i \log_b(1/p_i) \leq p_i \log_b(1/q_i) + q_i - p_i,$$

pentru orice i. Prin însumare obţinem

$$\sum_{i=1}^{n} p_i \log_b(1/p_i) \leq \sum_{i=1}^{n} p_i \log_b(1/q_i) + \sum_{i=1}^{n}(q_i - p_i).$$

Deoarece $\sum_{i=1}^{n}(q_i - p_i) \leq 0$, deducem că are loc

$$\sum_{i=1}^{n} p_i \log_b(1/p_i) \leq \sum_{i=1}^{n} p_i \log_b(1/q_i),$$

inegalitatea fiind satisfăcută prin egalitate dacă şi numai dacă $p_i = q_i$, pentru orice $1 \leq i \leq n$. □

Corolarul 3.5.5.1. Pentru orice distribuţie de probabilitate $p_1, \ldots, p_n$ are loc

$$0 \leq H(p_1, \ldots, p_n) \leq \log n.$$

Demonstraţie. Prima inegalitate urmează de la $p_i \log(1/p_i) \geq 0$, pentru orice i.

Folosind Lema 3.5.5.2 şi relaţia

$$\log n = \sum_{i=1}^{n} p_i \log(1/(1/n))$$

obţinem cu uşurinţă şi cea de a doua inegalitate. □

Corolarul 3.5.5.2. Pentru orice distribuţie de probabilitate $p_1, \ldots, p_n$ au loc relaţiile:

(1) $H(p_1, \ldots, p_n) = 0$ dacă şi numai dacă există i astfel încât $p_i = 1$;

(2) $H(p_1, \ldots, p_n) = \log n$ dacă şi numai dacă $p_1 = \cdots = p_n = 1/n$.

Demonstraţie. (1) Este clar că $\sum_{i=1}^{n} p_i \log(1/p_i) = 0$ dacă şi numai dacă $p_i \log(1/p_i) = 0$, pentru orice i. Ca urmare, va exista i astfel încât $p_i = 1$ (nu toţi p_j pot fi 0 deoarece $p_1, \ldots, p_n$ este o distribuţie de probabilitate).

(2) Conform Lemei 3.5.5.2, inegalitatea

$$H(p_1, \ldots, p_n) = \sum_{i=1}^{n} p_i \log(1/p_i) \leq \sum_{i=1}^{n} p_i \log(1/(1/n)) = log\, n$$

este satisfăcută prin egalitate dacă şi numai dacă $p_i = 1/n$, pentru orice i. □

În cazul unei surse cu 2 simboluri cu probabilităţile p şi $1-p$, funcţia H, privită ca o funcţie de o singură variabilă, are graficul din Figura 3.19.

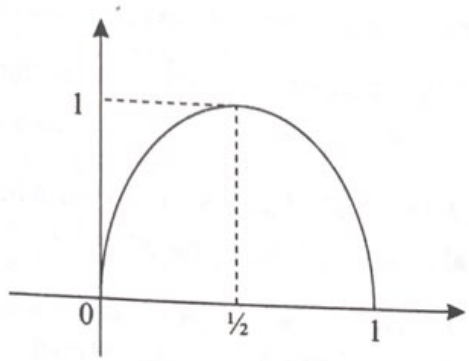

Figura 3.19: Funcţia $H(p, 1-p)$

Definiţia 3.5.5.2. *Produsul* a două surse de informaţie S_1 şi S_2, notat $S_1 \circ S_2$, este definit ca fiind sursa de informaţie

$$S_1 \circ S_2 = (\{(a_i, a_j) | 1 \leq i \leq n,\ 1 \leq j \leq m\}, (p_i \cdot q_j | 1 \leq i \leq n,\ 1 \leq j \leq m)),$$

unde $S_1 = (\{a_i | 1 \leq i \leq n\}, (p_i | 1 \leq i \leq n))$ şi $S_2 = (\{b_j | 1 \leq j \leq m\}, (q_j | 1 \leq j \leq m))$.

Este uşor de văzut că produsul a două surse de informaţie este sursă de informaţie. Atunci când $S_2 = S_1$ vom scrie S_1^2 în loc de $S_1 \circ S_2$, notaţie ce poate fi generalizată la un număr arbitrar de surse de informaţie.

Teorema 3.5.5.1. Pentru orice surse de informaţie S_1 şi S_2 are loc

$$H(S_1 \circ S_2) = H(S_1) + H(S_2).$$

Demonstraţie. Au loc relaţiile:

$$\begin{aligned} H(S_1 \circ S_2) &= \textstyle\sum_{i,j} p_i q_j \log(1/(p_i q_j) \\ &= \textstyle\sum_{i,j} p_i q_j \log(1/(p_i) + \sum_{i,j} p_i q_j \log(1/(q_j) \\ &= (\textstyle\sum_j q_j)(\sum_{i,j} p_i \log(1/(p_i)) + (\sum_i p_i)(\sum_{i,j} q_j \log(1/(q_j)) \\ &= H(S_1) + H(S_2) \end{aligned}$$

ce demonstrează teorema. □

Direct de la Teorema 3.5.5.1 obţinem:

Corolarul 3.5.5.3. Dacă S este o sursă de informaţie, atunci pentru orice $k \geq 1$ are loc $H(S^k) = kH(S)$.

Teorema 3.5.5.2. (Teorema lui Shannon pentru canale fără zgomot)
Fie S o sursă de informaţie. Atunci au loc următoarele proprietăţi:

(1) $H(S) \leq L_h(S)$, pentru orice codificare h a sursei de informaţie S;

(2) $H(S) \leq L_h(S) < H(S)+1$, pentru orice codificare prefix h a sursei de informaţie S;

(3) $lim_{k\to\infty} \dfrac{L_{min}(S^k)}{k} = H(S)$, unde $L_{min}(S')$ reprezintă lungimea medie (minimă) a unui cod Huffman al sursei de informaţie S'.

Demonstraţie. (1) Fie h o codificare pentru sursa de informaţie S cu n simboluri $a_1, \ldots, a_n$ şi distribuţia de probabilitate $p_1, \ldots, p_n$. Atunci:

$$\begin{aligned} L_h(S) &= \textstyle\sum_{i=1}^n p_i|h(a_i)| \\ &= \textstyle\sum_{i=1}^n p_i \log 2^{|h(a_i)|} \\ &= \textstyle\sum_{i=1}^n p_i \log(1/(1/2^{|h(a_i)|})). \end{aligned}$$

Deoarece $0 \leq 1/2^{|h(a_i)|} \leq 1$ şi $\sum_{i=1}^n 1/2^{|h(a_i)|} \leq 1$ (conform inegalităţii Kraft-McMillan), în baza Lemei 3.5.5.2 urmează $H(S) \leq L_h(S)$.

(2) Este suficient de arătat că are loc $L_h(S) < H(S) + 1$, pentru orice cod prefix al sursei de informaţie S.

Pentru orice i există un număr natural $d_i \neq 0$ astfel încât

$$\log(1/p_i) \leq d_i < 1 + \log(1/p_i).$$

Atunci:

$$\sum_{i=1}^n (1/2^{d_i}) \leq \sum_{i=1}^n (1/2^{\log(1/p_i)}) = \sum_{i=1}^n (1/(1/p_i)) = 1.$$

Ca urmare, conform Teoremei 3.5.3.2, există un cod prefix h ce satisface $|h(a_i)| = d_i$, pentru orice i. În plus:

$$\begin{aligned} L_h(S) &= \textstyle\sum_{i=1}^n p_i d_i \\ &< \textstyle\sum_{i=1}^n p_i(1 + \log(1/p_i)) \\ &= \textstyle\sum_{i=1}^n p_i + \sum_{i=1}^n p_i \log(1/p_i) \\ &= H(S) + 1. \end{aligned}$$

(3) Conform cu (2), are loc $H(S^k) \leq L_{min}(S^k) < H(S^k) + 1$, ceea ce conduce la

$$H(S) \leq \frac{L_{min}(S^k)}{k} < H(S) + \frac{1}{k},$$

de unde obţinem concluzia teoremei. □

Observaţia 3.5.5.1.

(1) Codurile de lungime variabilă se utilizează în special pentru compresia informaţiei, fără a lua în calcul erorile care pot apare atunci când informaţia este transmisă pe un canal de transmisie (ca şi cum canalul nu ar altera informaţia ce îl parcurge). Cum canalele de transmisie se clasifică în canale cu zgomot (ce pot produce erori) şi canale fără zgomot (ce nu produc erori), aceasta justifică denumirea Teorema 3.5.5.2 (a se vedea şi Secţiunea 6.6).

(2) Teorema 3.5.5.2(1) ne spune că lungimea medie a codurilor Huffman pentru o sursă de informaţie S nu poate scădea sub $H(S)$. Punctul (3) al aceleeaşi teoreme ne spune că, grupând din ce în ce mai multe simboluri ale sursei de informaţie şi asociind acestora coduri Huffman, lungimea medie tinde la $H(S)$.

(3) Există tehnici de compresie pentru care lungimea medie scade sub entropia sursei de informaţie. Pentru detalii cititorul este îndrumat către [173].